

Enquête usages MathAData

Architecture de la pipeline & appariement site ↔ Capytale

— équipe technique + équipe déploiement / données / formation

3

sources de données

2023→26

3 ans Capytale

0

donnée perso publiée

Ce qu'on veut couvrir

1 — La pipeline

pourquoi · principes · 3 sources · fonctionnement

2 — L'appariement site ↔ Capytale

aucune clé commune · ce qu'on a choisi · limites · alternatives

Fil rouge de chaque sujet : *pourquoi* (la question) → *les données dispo & contraintes* → *comment on a fait* → *détails d'implémentation* → *limites*.

Le principe directeur : deux mondes disjoints




Conséquence cardinale : tout ce qui relie les mondes est **estimé**, jamais mesuré. On le dit à chaque chiffre.

Partie 1

La pipeline : principes, sources, fonctionnement

Pourquoi une pipeline (et pas des scripts ad hoc)

Le problème : 3 sources · 4 analyses · des dizaines de chiffres publiés · plusieurs sessions. Sans discipline → chaque script redéfinit « classe », « prof », « rétention » → **chiffres qui se contredisent**.



→ Reproducible (`rebuild_all.sh`), **idempotent**, vérifiable, **sans PII**.

Les trois sources de données

CAPYTALE

1 ligne = 1 clone · anonyme (MD5)

2023→2026 ·  versionné

API c-stat/mathadata, token .env.local

PAYLOAD (site)

users / sessions / events / clics · nominatif

clics ≥ 27/11/25 ·  LOCAL & gitignore (PII)

MATHADATA_SNAPSHOT fige une extraction

URLR (Basthon)

clics/uniques par fenêtre · agrégé, aucune identité · liens ≥ 25/12/25 ·  versionné · fetch réseau HORS rebuild


	grain brut	nature	clé d'identité
Capytale	affectation (clone)	usage classe	MD5 ENT (anonyme)
Payload	compte / clic	intention amont	nominatif (local)
URLR	compteur / fenêtre	volume sans compte	aucune

La donnée brute Capytale : 1 ligne = 1 clone

role TYPE du compte teacher / student	teacher distributeur = l'identité prof	student propriétaire du clone (élève ou stagiaire)	uai_teach uai_el établissements	mathadata_id activité-maître = LE PONT web/b/<id>
--	---	---	---	--

Pièges canoniques — ⚠ ne JAMAIS compter les profs via `n_teacher_clones` : **59 % des profs (133/224)** n'ont aucun auto-test (« plongée directe »). Compter = `distinct(teacher)` sur lignes `role=student` . · Isoler le **hub fondateur** `cfcd2084...` (MD5 "0", 404 él. / 14 étabs). · Exclure le **compte démo** `c81e728d...` (MD5 "2").

La chaîne `rebuild_all.sh` — une seule commande



Boîtes pleines = **toujours** rejouées (depuis `public/data`). Boîtes pointillées = **auto-sautées** sans le snapshot PII (clone public). **Idempotent** : re-run = aucune dérive.

Le socle partagé **K** (`enquete_common.py`)

Source **unique** des constantes — tout script `import enquete_common as K`. On ne redéfinit JAMAIS un seuil localement.




Populations **ancrées** (`K.EXPECT`) : les contrats cassent si une régénération les fait bouger sans revue consciente.
Fonctions : `school_year()` (coupure **1^{er} août**), `exclude_special()`, `sanitize_json()`.

Cœur algorithmique : reconstruction des séances


Capytale ne donne pas la notion de séance → on la reconstruit par **clustering temporel**.

Séance = run maximal de clones **ÉLÈVES** de même (teacher, mathadata_id, uai_el), créations consécutives espacées de < 3 h.




⚠ **Durée médiane d'un run ≈ 7 min** : ce sont des **salves** (créneau de connexion), pas la durée du cours. Demi-groupes (même activité, 5-15 él., < 10 j) fusionnés en **1 occasion**.

L'escalier de profondeur 0→5 (par prof × année)



Barreaux **exclusifs** : chaque prof-année tombe dans un seul. Les deux mondes ne se recouvrent que par l'appariement (75 paires).

Le funnel complet : du site... au mur de l'univers Capytale




🚫 changement d'univers — aucun identifiant commun · 44 % des établissements à usage n'ont AUCUN compte site



Le ratio **224 / 2 715 (~8 %)** n'est **PAS un taux de conversion** : deux populations partiellement disjointes. Les seuls taux propres sont **intra-univers** (Capytale : 401 engagés $\rightarrow$ 224 ont enseigné = 56 %).


facts_*.json : on lit, on ne recalcule pas



Règle de réponse : chercher d'abord dans les **facts**, puis dans les **tables** ; ne recalculer que l'inexistant — et alors depuis les tables canoniques, jamais en redéfinissant un terme.

Anti-dérive : ce qui empêche les chiffres de mentir

`check_contracts.py` doit finir par ☒ tous les contrats respectés :



Un chiffre **ne peut pas diverger en silence**.

Partie 2

L'appariement site ↔ Capytale

Pourquoi : les questions à trancher

On sait **séparément** ce qui se passe sur le site (intention) et sur Capytale (usage classe). On veut reconstituer **le pipeline complet** et répondre à des questions de déploiement.

Formation → classe ?

quel format / concentration convertit ?

Porte d'entrée ?

site-first vs Capytale-direct

Canal & formation

d'un prof Capytale → alimenter les profils

Intention → usage ?

le déclaré prédit-il le réel ?

→ Toutes exigent de **relier** un compte site (nominatif) à un usage Capytale (anonyme).

La contrainte fondamentale : aucune clé commune



- Capytale **anonyme par conception** (RGPD/ENT) : le MD5 n'est rattachable à personne.
- Les **seuls attributs partagés : UAI + activité + temps**. Pas de jointure possible → le lien est **inféré**.

Décision de cadrage : conclusions robustes au grain **établissement / cohorte**. L'individuel est un **bonus inféré, à confiance signalée** : il *alimente le canal* et *illustre*, il ne *mesure pas* une population.

Le seul pont direct : le clic `web/b/<id>`



Le pont s'arrête au clic. Cliquer le lien ≠ cloner sur Capytale (le clonage ENT en aval est anonyme). Donc même avec le pont, relier *le clic* au *bon compte Capytale* reste une inférence : **même UAI + même activité + timing.**

Le déclic : qu'est-ce qui est partagé entre les deux mondes ?

SITE

nom · e-mail · formé ?

(qui, nominatif)

commun aux DEUX

★ l'établissement (UAI)

★ l'activité (mathadata_id)

CAPYTALE

hash anonyme · clones

(usage classe)

L'idée centrale : il n'y a pas d'identité commune, **mais l'UAI et l'activité existent dans les deux mondes**. → On ne relie pas des **personnes**, on relie des **établissements** et des **activités**. Tout le reste en découle.

Trois façons de relier (du + robuste au + fragile)

1

grain ÉTABLISSEMENT

clé = **UAI** (exacte, dans les 2 mondes) · **mesure l'impact formation en classe** · robuste mais **écologique** (peut-être un collègue)

2

grain SITE pur

« formé → a cliqué » · **pas besoin de pont** (2 events du site) · mesuré proprement, mais = **intention**, pas usage classe


3

grain INDIVIDU

le **pont du clic** (web/b) · tente « cette personne = ce compte Capytale » · **inféré**, bonus illustratif, confiance signalée

L'**impact formation** repose surtout sur la **méthode 1**. La 3 *raconte*, elle ne *mesure* pas.

Méthode 1 — grain établissement : pas à pas



Limites : ⚠ **écologique** (l'utilisateur peut être un collègue, pas le formé) · ⚠ **UAI déclaré** seulement par **317/631 formés** · ⚠ **endogénéité** (9/26 étabs déjà actifs avant la formation). → direction robuste, **chiffre = ordre de grandeur**.

Exemple concret : un lycée suivi des deux côtés

Côté SITE (nominatif)

- 3 profs du « lycée Pasteur » inscrits
- 2 formés en oct. 2024 (on a leurs e-mails)
- 1 seul a renseigné l'UAI 0590XXXX

Côté CAPYTALE (anonyme)

- à l'UAI 0590XXXX : 309 lignes `role=student`
- activités Géométrie + Stat, mai 2025
- distribuées par un hash `a3f8...`


lien = l'UAI

→ « le lycée Pasteur a basculé en usage classe »  — mais **on ne sait pas lequel des 3 profs** est le hash a3f8...

C'est tout le sens (et la limite) du grain établissement : « **l'établissement a bougé** » est sûr ; « **le formé a enseigné** » ne l'est pas.


Méthode 2 — site pur : l'intention (sans pont)

« Formé » et « a cliqué un lien Capytale » sont **deux événements du site** → comparaison interne, pas besoin de relier les mondes.



✓ **Mesuré proprement** (1:1 dans le site). ⚠ Mesure l'**intention** (le clic), **pas** l'usage en classe. ⚠ Auto-sélection (on forme des gens déjà motivés). → C'est un 2^e « **effet formation** », distinct de l'aboutissement-classe (méthode 1) — ne jamais les confondre.

Méthode 3 — appariement individuel : le pont du clic



75 paires au total — un **bonus illustratif** à confiance signalée. Détail des règles (A/D/E/B) page suivante.

Anatomie d'une ligne Capytale (1 ligne = 1 clone)

`role` = qui **possède** le clone · `teacher` = qui le **distribue** · `student` = le propriétaire

① Déploiement direct (« plongée directe ») — 59 % des profs

```
role=student teacher=a3f8... student=<élève> uai_teach=0590X mathadata_id=3515488 × 28
```

→ Mme Martin : **28 lignes role=student, 0 ligne role=teacher**. Visible **seulement** par D/E.

② Prof qui s'auto-teste d'abord

```
role=teacher teacher=b7c2... student=b7c2... (l'auto-test : il est son propre owner)
role=student teacher=b7c2... student=<élève> (puis ses élèves)
```

→ M. Durand : 1 ligne `role=teacher` + lignes `role=student`. Visible par A/B.

③ Formation (formateur + stagiaire)

```
role=teacher teacher=X(formateur) student=Y(stagiaire) uai_teach=<X> uai_el=<Y>
```

→ Le stagiaire Y est `role=teacher`, son id est dans la colonne `student`. Compté (à tort) par `n_teacher_clones`.

Compter un prof = `distinct(teacher)` sur les lignes `role=student`. Les signaux A/B ne voient que les profs de ② (qui ont une ligne `role=teacher`) → d'où D/E, qui lisent le **vrai enseignement** (`role=student`) et récupèrent ceux de ①.

Méthode 3 en détail : les 4 signaux (A · D · E · B)

A

timing · haute

user clique act. A à T ; **UN SEUL** compte Capytale `role=teacher` a cloné A au **même UAI** dans `[T-2j, T+60j]`

D

déploiement · haute/moy.

UAI à **1 seul prof réel** (a des élèves) **et 1 seul** cliqueur site → apparié (A si l'activité recoupe, sinon B) — récupère la « **plongée directe** »

E

déploi.xact. · haute

UAI multi-comptes : une activité n'a qu'**1** déployeur + **1** cliqueur (déploi. après clic) → désambiguise

B

UAI 1:1 · moyenne

exactement **1** compte site et **1** compte Capytale-teacher sur l'UAI

Combinaison par priorité croissante **A (0) < D/E (1) < B (2)** ; on garde **1 site** ↔ **1 Capytale**.

Le piège qui a forcé D et E

A et B ne voient que les comptes `role=teacher` (auto-tests). Or **59 % des profs (133/224)** ne se testent JAMAIS — ils distribuent directement (« plongée directe »). A/B les rataient **tous**.



C'est exactement le même piège que `n_teacher_clones` : confondre « s'est auto-testé » et « est un prof ». Prof réel = MD5 `teacher` ayant ≥ 1 ligne `role=student` ; son UAI est sur `uai_teach` de ses lignes élèves.

Résultats & pseudonymisation à deux niveaux




Ordre de sortie **déterministe** (idempotence). Calibré sur le pionnier (Haubourdin 0590093F) + UAI 1:1.

Galerie de cas concrets (appariement individuel)

Réf	Établissement	Profil	Chaîne observée	Ce que ça illustre
A	Le Vigan (Montpellier)	présentiel · conf A	compte créé le jour de la formation , clone « Éq. réduite » le jour même, 0 élève encore	amorçage immédiat (classes à la rentrée)
B	Orsay (Versailles)	webinaire · conf A	3 activités, 65 élèves sur 5 séances · 2 comptes au même UAI	étab sûr, collègue ambigu
C	Poissy (Versailles)	non formé · conf A	60 élèves · 1 ^{er} clone avant le clic site	flèche inversée + productif sans formation
D	Douai (Lille)	webinaire · conf B	99 élèves , 9 séances sur 2 ans	ré-utilisateur durable
E	Ciboure (Bordeaux)	petit collège · conf B	chaîne complète mais 3 élèves	faux positif coûteux , signal fragile

Ces 5 cas couvrent les situations-types : converti-vite · collègue-indistinct · déjà-autonome (le site n'est qu'un retour) · installé-dans-la-durée · trop-petit-pour-être-sûr. **L'individuel donne à voir le scénario ; il ne le chiffre pas.**

Exploitation (1) — les deux portes



Insight : 44 % des établissements à usage n'ont **aucun compte site**. La découverte « froide » passe par le **catalogue Capytale** et le bouche-à-oreille, pas par le SEO. Le site est surtout un canal de **préparation et de relance**.

Exploitation (2) — l'effet formation

Croisement **cohorte** × **usage élève établissement** (historique Capytale complet, **non biaisé** par la fenêtre de tracking) :

Établissement-ciblée 59 % (13/22 étabs)

Distanciel / webinaire 30 % (18/61)


Académique de masse 10 % (13/126)

Ce n'est pas le format qui prédit l'aboutissement, c'est la concentration — facteur ~6, alors que ciblée et masse sont **toutes deux du présentiel**. → Levier déploiement n°1.

Endogénéité : **9/26** étabs présentsiels à usage utilisaient déjà Capytale **avant** la formation. Base petite (22 étabs) → ordre de grandeur, direction robuste.


Exploitation (3) — figer le canal & timer la formation

L'appariement (ou, à défaut, la **trace établissement**) alimente `build_profiles.py` :



Règle stricte : proxy_etab sert un **agrégat**, **jamais** une identité nominative. On sépare toujours : (1) formés agrégés ; (2) appariements A/B ; (3) personnes nominatives uniques.

Lecture façon Sankey : canal → profondeur (les 260 profs)



Largeur du ruban = nb de profs. **via_site** : 74 % atteignent une classe (uniq+multi), 30 % en usage multiple. **Capytale-direct** : davantage en test/sous-seuil. ⚠ **Descriptif** — le canal est *estimé* (cf. les 3 régimes, ci-après).

Les Sankeys flux : deux objets distincts (le piège n°1)

Funnel SITE

2 715 → 1 712 → 631 formés → 337 clic

1:1 **intra-site** · mesuré · s'arrête à l'**intention** (le clic)

Sankey FLUX (canonique)

260 / 223 / 176 profs **Capytale**

1:1 **intra-Capytale** · l'escalier = 0/1/plusieurs usages

le pont entre les deux = ESTIMÉ

canal « via_site » & statut « formé » d'un prof Capytale = attribués, pas joints

⚠ **On ne chaîne JAMAIS** « formés site → usage Capytale 0/1/plusieurs » au grain individuel : mondes disjoints. Le « combien de fois en classe » est mesuré **côté Capytale** ; le « formé » y est **posé par estimation**. Le funnel site, lui, ne voit rien après le clic.

D'où viennent les rubans : 3 régimes de confiance


Pour chacun des **260 profs Capytale**, `build_profiles.classify()` attribue canal + formation :



Seuls ~28 % des profs (74/260) ont un lien 1:1. 18 % par **moyenne d'établissement**, 54 % par **défaut**. → « capytale_direct » et « jamais formé » sont des **bornes** : elles incluent « on n'a pas vu de trace », pas seulement « prouvé absent ». D'où le ruban **estimé**.

Sankey « formé → profondeur » : porte sur les **67 profs Capytale tagués formés** (≠ 631 site) → 9 test · 7 sous-seuil · 24 usage unique · 27 usage multiple. La conversion « formation→classe » (59/30/10 %) est, elle, au **grain établissement** (agrégé).

Ce qu'on ne peut pas suivre (recensement des pertes & biais)



Le risque principal : lire un ruban « capytale_direct / jamais formé » comme une **mesure** alors que, pour la moitié des profs, c'est une **absence de trace** (UAI manquant, tracking tardif, pas d'appariement). Tous ces chiffres restent des **ordres de grandeur** au grain établissement, jamais des taux individuels.

Limite de premier ordre : couverture UAI ⊥ maturité

La conversion « formation→classe » exige l'UAI. Or **la couverture est inversement corrélée au recul** :

Cohorte	profs	avec UAI	
Lille oct. 2024 (18 mois de recul)	40	6	le 66,7 % repose sur 6 étabs
Amiens	19	1	
ENS_25 sept. 2025	52	3	
Présentiel 2026-03	39	39	couverture quasi totale...
Présentiel 2026-05	42	41	...mais pas encore de recul

La tension structurelle : les cohortes **mûres** (le meilleur recul pour juger « a fini par déboucher ») ont la **pire** couverture UAI ; les cohortes **2026** (couverture quasi parfaite, le formulaire capte l'UAI depuis janv. 2026) **n'ont pas encore déployé**. → précision dégradée ; on n'affirme que la **direction** (concentration » dispersion), corroborée par le terrain (Lille 2024 = 841 élèves, *mesurés*).

Correctif possible (livrable « données ») : rendre l'UAI **obligatoire** à l'inscription / en formation, ou le récupérer via le roster de formation — réglerait le problème pour l'avenir.

Les limites honnêtes (les drapeaux assumés)

13/75

ont cloné AVANT de cliquer le site → « site→classe » inversé (canal de retour)

2 UAI

portent 2 comptes Capytale → étab certain, bon prof non

conf. B

UAI 1:1 sans timing → faux positifs (petits collègues)

≥ 27/11/25

tracking des clics → clics antérieurs sous-captés → sur-attribution à capytale_direct

non représentatif

sur-représente les profils engagés → jamais extrapolé en taux de population

Doctrine : *l'individuel confirme le scénario, il ne le mesure pas.*


Les autres options — et pourquoi pas (pour l'instant)

Option alternative	Pourquoi écartée
Clé commune via Capytale (id / e-mail hashé partagé)	Gouvernance/RGPD : anonyme par conception. <i>La vraie solution long terme.</i>
Record linkage probabiliste (Fellegi-Sunter, scoring pondéré)	Aucun champ nominatif côté Capytale à comparer — seuls partagés : UAI + activité + temps
Fuzzy matching sur nom étab/prof	Pas de nom côté Capytale ; l'UAI est déjà exact
Classifieur ML supervisé	Pas de vérité terrain (aucune paire certifiée pour entraîner/valider)
Score bayésien continu	Possible, mais opaque — préféré : règles déterministes auditable + conf. A/B

Notre choix : règles déterministes **conservatrices** (déclenchées sur l'unicité seule), confiance **signalée, calibrées** sur cas connus. Transparence & zéro faux positif PII > rappel maximal — vu l'enjeu et l'absence de vérité terrain.

URLR / Basthon : le même problème, à l'extrême


Pourquoi : Capytale ne voit pas l'usage **sans compte** (liens courts Basthon). Combien d'usage passe par ce canal ?



- Séance estimée = run d'heures actives même lien, débuts < 3 h (même logique que Capytale).
- Taille `n_visiteurs_uniques_urlr` — **non additive**, clé de dédup **non documentée**, **IP anonymisées** → un **NAT d'établissement sous-compte une classe** (clics/unique : 2,97, jusqu'à 6,3).
- Parades : **proxy par clics** (1 clic = 1 participation, exploratoire) + **NAT-suspect** (≤ 4 uniques mais ≥ 10 clics).
- Croisement Capytale **national & inféré** (chevauchement temporel) : modes *remplacement* / *dépannage compatibles* — jamais une attribution certaine.

Synthèse

Les principes transférables



Ce que l'appariement permet — et ne permet pas

✔ Permet	✗ Ne permet pas
Mesurer l'effet formation au grain établissement	Affirmer « tel prof = telle personne » avec certitude
Reconstituer les deux portes (site vs Capytale-direct)	Un taux de conversion site → classe individuel
Figurer le canal & timer la formation des profils	Attribuer une salve URLR à un prof (sauf copie + A/B)
Illustrer le pipeline par des cas réels	Extrapoler les 75 paires en population

La phrase à retenir : *deux mondes sans clé commune, un seul pont qui s'arrête au clic — donc tout lien est inféré, conservateur, et à confiance signalée.*

Discussion

: code du matcher (`match_individuals.py`), glossaire canonique, rapports Volet 1 / Volet 2 / Typologie / Séances / URLR, dashboards publiés (`mathadata.github.io/enquete-usages`).

Tous les chiffres : pseudonymisés, sans PII, reproductibles via `rebuild_all.sh`.